Matemàtica Computacional i Analítica de Dades - Universitat Autònoma de Barcelona

Image Captioning sobre Flickr8k

De ResNet18 + GRU a ViT-GPT2: mètriques, biaixos i interpretabilitat

Aleix Artal
Jan Munts
Hèctor Sánchez

Xarxes Neuronals i Aprenentatge Profund - Grup 07
Curs 2025-26

Problema i objectiu

Generar una descripció textual relativament curta d'una imatge

Què és image captioning?

- Entrada visual → sortida en llenguatge natural
- Combina visió per computador (extreure objectes, escenes, accions) i NLP (generar una frase coherent)
- Arquitectures típiques: encoder visual + decoder seqüencial



➡

"A young boy wearing a red shirt runs along a gravel road"

Els nostres objectius

- Construir un baseline complet i avaluar-lo amb rigor
- Iterar amb cerca d'hiperparàmetres (W&B sweep)
- Obtenir bons resultats segons les mètriques
- Diagnosticar biaixos sistemàtics del model
- Mitigar-los sense degradar les mètriques principals

Dataset - Flickr8k

8 091	5	~40 K	4 623
imatges	captions / imatge	parelles (img, text)	tokens (vocab. baseline)



A child in a pink dress is climbing up a set of stairs in an entry way .

A girl going into a wooden building .

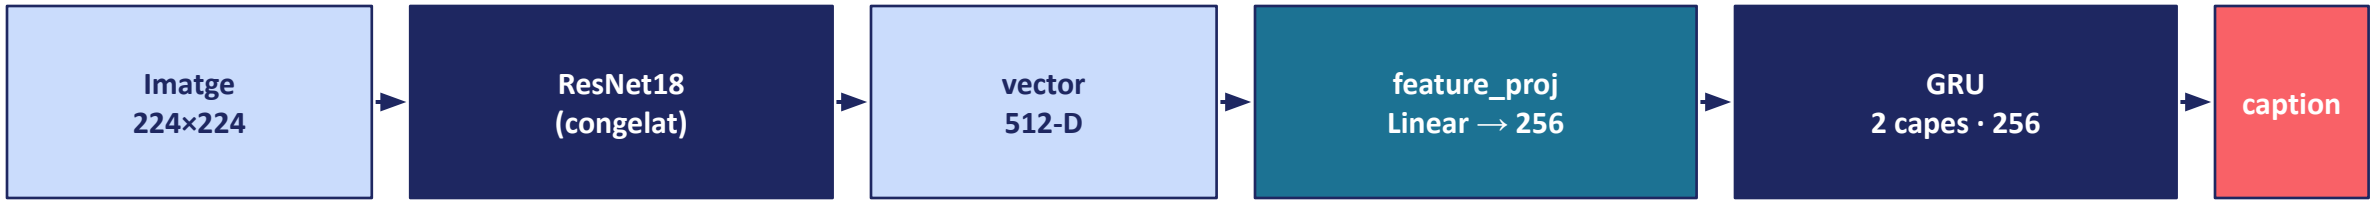
A little girl climbing into a wooden playhouse .

A little girl climbing the stairs to her playhouse .

A little girl in a pink dress going into a wooden cabin .

Baseline - ResNet18 + GRU

Encoder–decoder amb teacher forcing



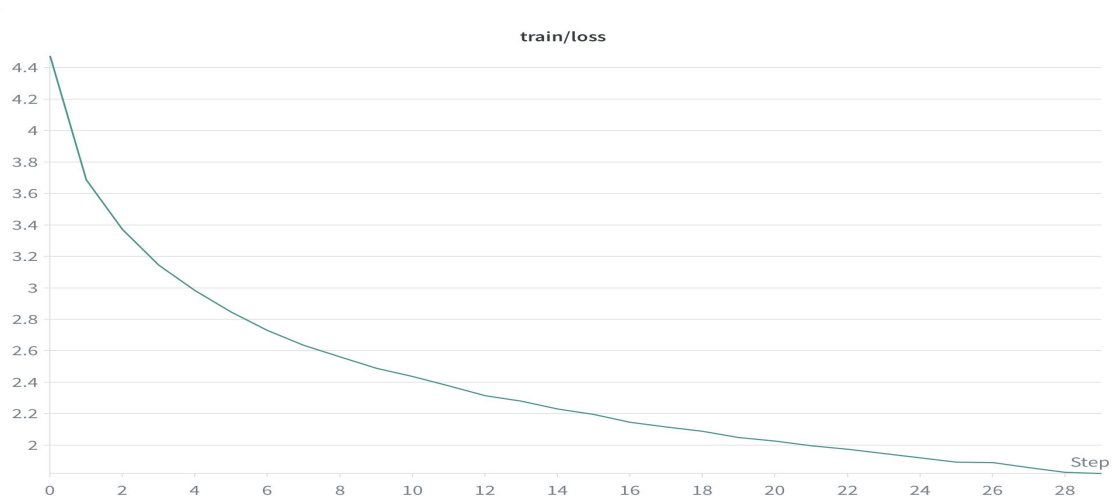
Arquitectura del model

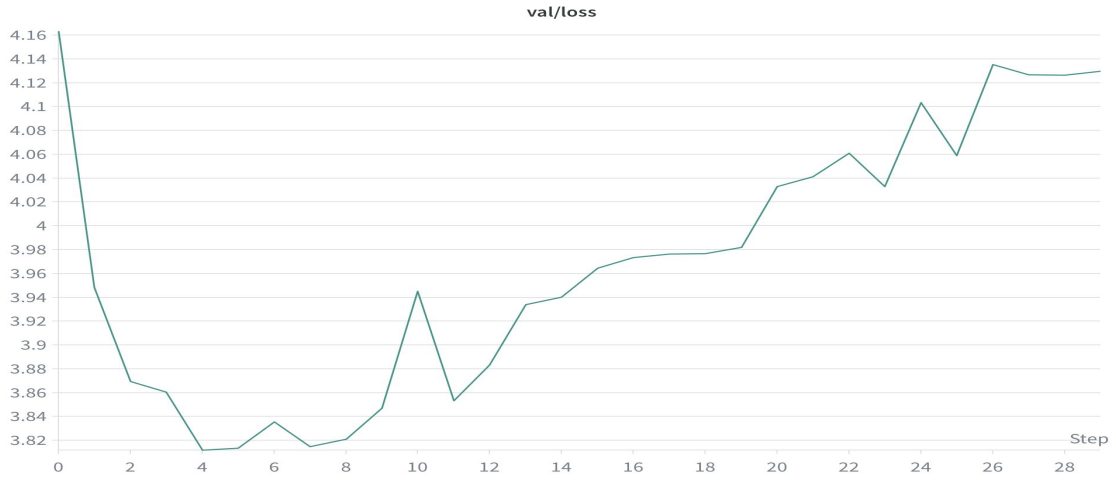
- Encoder ResNet18 pre-entrenat a ImageNet i congelat
- Decoder GRU de 2 capes amb embedding de 512 dimensions i 256 hidden_dim
- Vocabulari per caràcter (4 623 tokens, min_freq=2)
- Adam amb learning rate fix, 30 epochs i batch 32
- Splits: 75% train, 12.5% val i 12.5% test
- Mètrica BLEU: Overlap d'n-grams entre predicció i referència.

Bleu: a Method for Automatic Evaluation of Machine Translation (Papineni et al., ACL 2002)

Mètrica i resultats del baseline

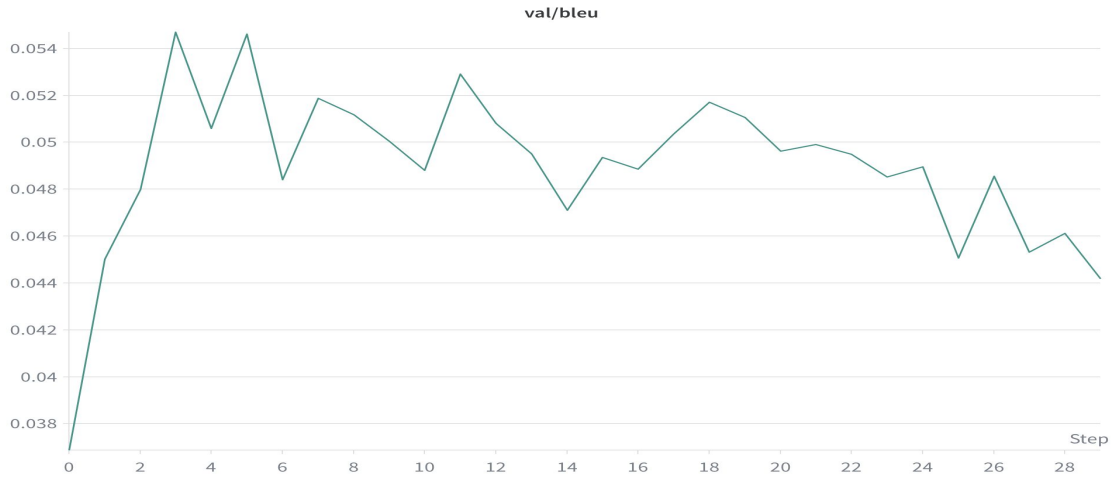
30 epoch





val loss mínim al pas 4 → overfitting





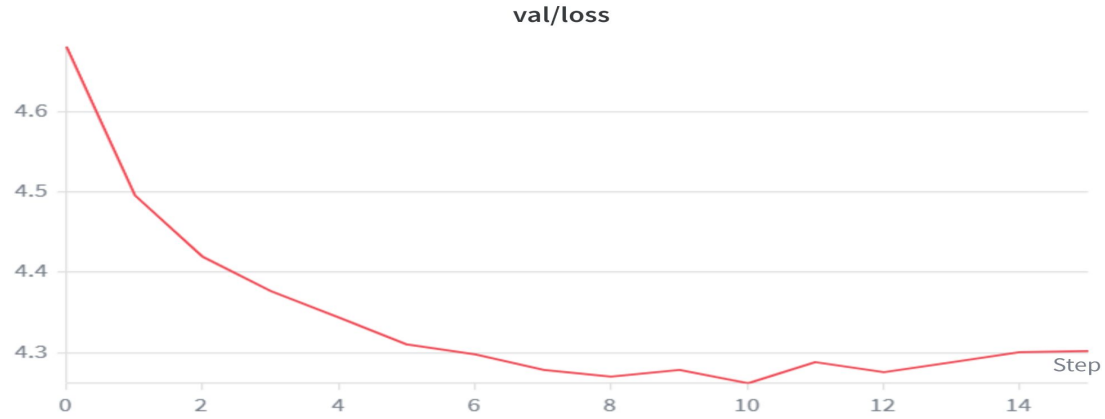
val BLEU-4 màxim al pas 3 i 5 (coherent amb val loss) → overfitting

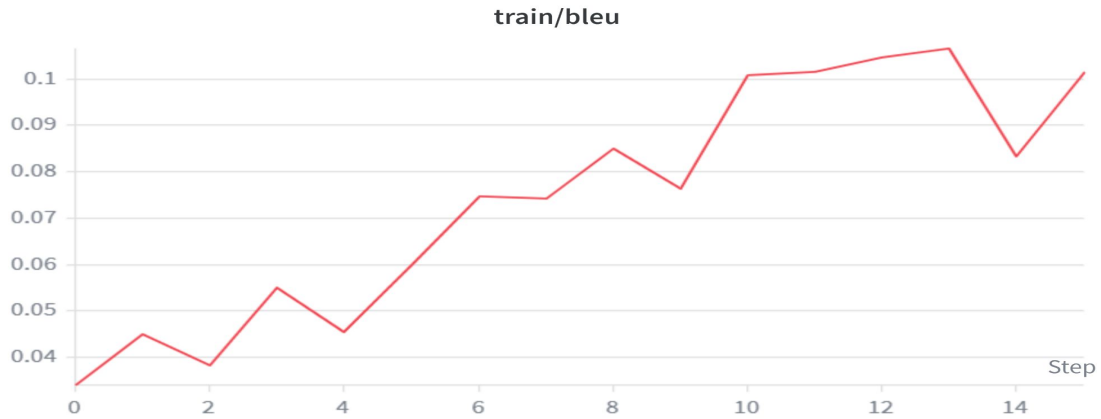
Addició i cerca d'hiperparàmetres

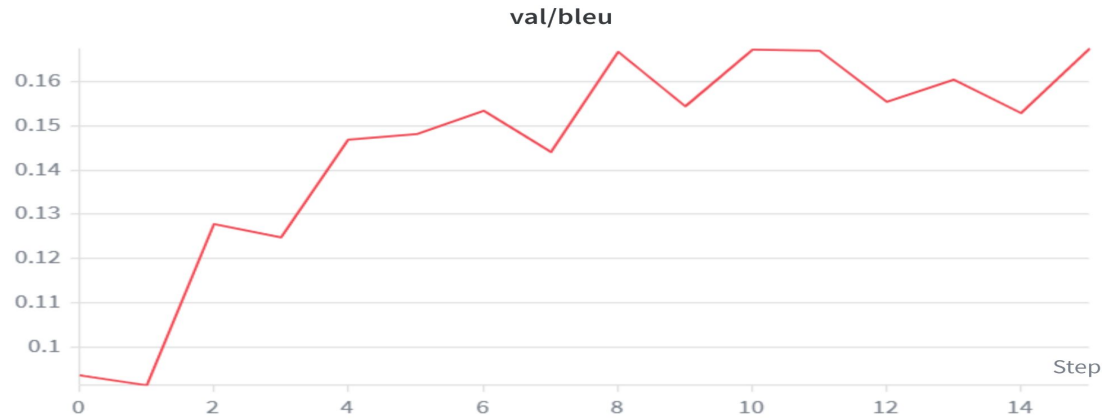
15 epoch

batch_size=16, dropout=0.2416, hidden_dim=768, lr=0.000122, weight_decay=0.0002









Resultats del baseline de test

Mètrica	Valor
Test loss (CE)	3.7314
Test BLEU-1	0.634
Test BLEU-4	0.164
Vocab (min_freq=2)	4 623
Paràmetres	~15.8 M

Anàlisi qualitatiu

- Plantilles repetides: "a X in a red shirt"
- Errors freqüents: plural/singular i presència d'objectes



Predicció:
a boy in a red shirt is kicking a soccer ball.

Referència:
Two boys and a ball.



Predicció:
a man in a red shirt is walking on a city .

Referència:
A bearded man with a backpack on his back holding a tripod in front of a rocky creek and bridge .

Per què canviar de paradigma?

Estem prop del sostre del baseline, millorar-lo requereix repensar l'arquitectura

Limitacions del baseline

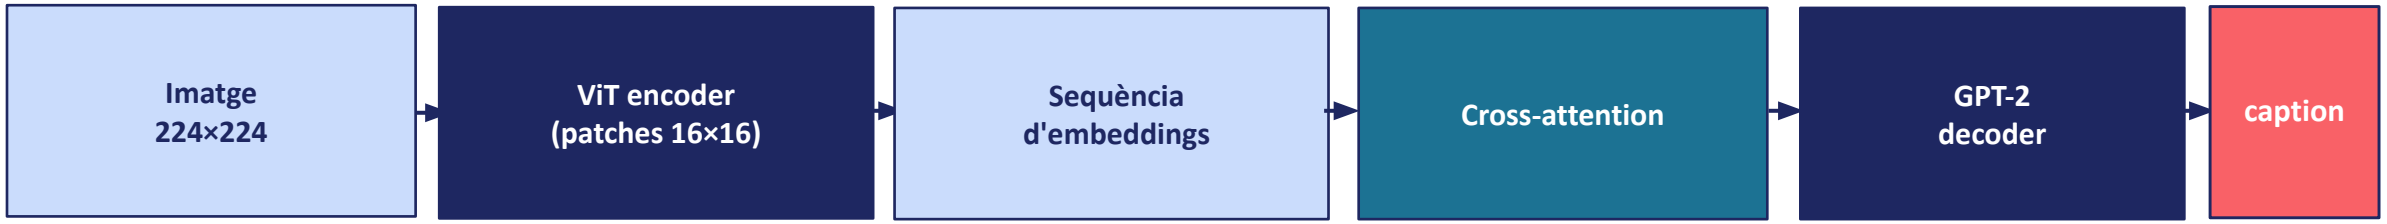
- Sense atenció: la imatge entra una sola vegada com a estat inicial
- Encoder ResNet18 amb pool global → es perden les regions
- Vocabulari per caràcter → frases curtes, lèxic simple
- BLEU de validació no gaire alt i overfitting evident

Què ens dóna ViT-GPT2

- Atenció completa: cross-attention a cada token de sortida
- Encoder ViT pre-entrenat a ImageNet-21k
- Decoder GPT-2 amb Byte-Pair Encoding (BPE) → vocabulari ric, frases naturals
- Pre-entrenament del decoder → ja sap escriure anglès
- Coexistència de fine-tuning per capes i descongelació progressiva

ViT-GPT2 - arquitectura i estratègia

nlpconnect/vit-gpt2-image-captioning (HuggingFace)



Estratègia de fine-tuning

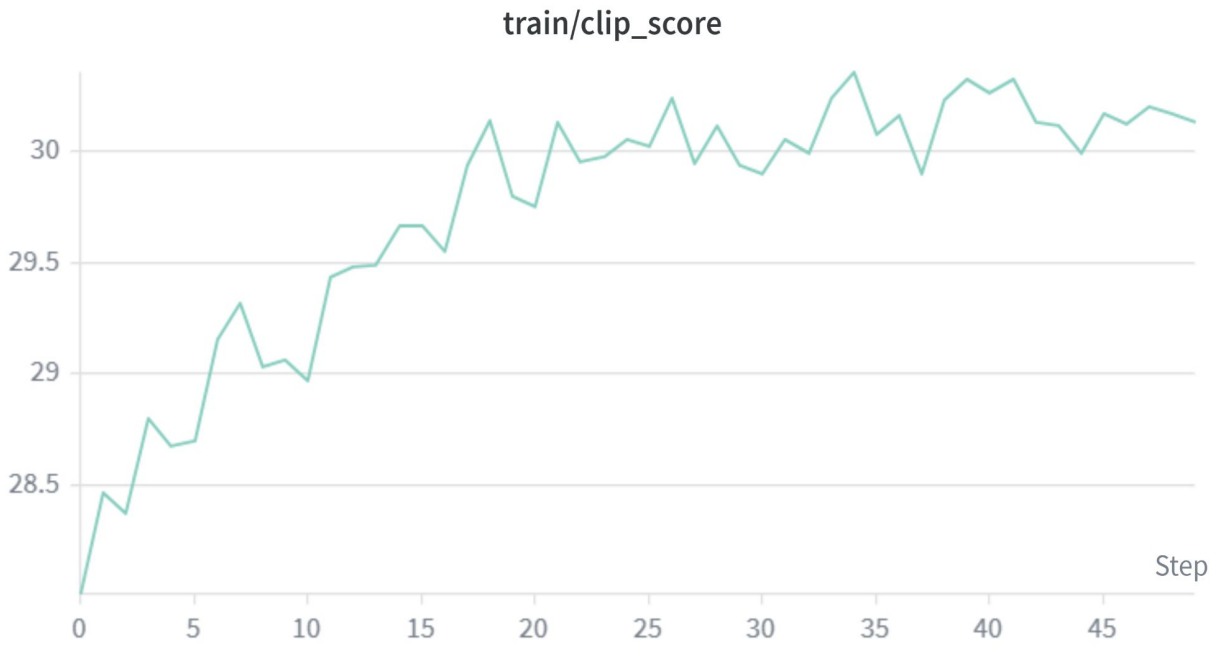
- Encoder ViT congelat les primeres èpoques
- Descongelació progressiva en una època fixada
- Learning rate amb warmup lineal + CosineAnnealing

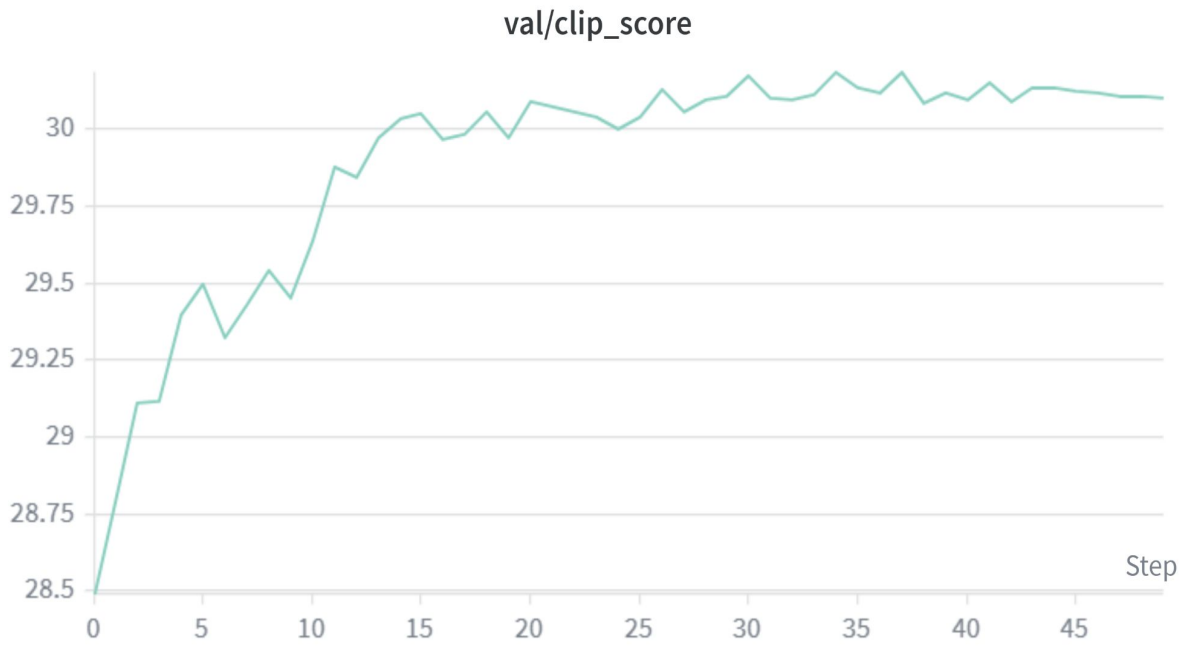
Canvi de mètrica: CLIP Score

- Mesura similitud semàntica directament entre imatge i text
- No requereix referències humanes
- Escala 0-100; valors típics 25-35 per captioning anglès

CLIPScore: A Reference-free Evaluation Metric for Image Captioning (Hessel et al., EMNLP 2021)

Resultats del ViT-GPT2 + *fine-tuning* (CLIP)





Comparació de mètriques i models

Models	#Params	BLEU-1	BLEU-2	BLEU-3	BLEU-4	CLIPScore
ResNet18+Gru (Baseline)	**15.8M**	**0.634**	**0.397**	**0.254**	**0.164**	**24.46**
ViT-GPT2 (Zero-shot)	**123M**	**0.626**	**0.432**	**0.280**	**0.176**	**28.70**
ViT-GPT2 (fine-tuned)	**123M**	**0.724**	**0.541**	**0.397**	**0.291**	**30.18**

Benchmarking amb altres treballs (Flickr8k, BLEU corpus amb 5 refs)

- Google NIC – Show and Tell (Vinyals 2014) BLEU-1 = 0.63
- Log Bilinear (Kiros 2014) BLEU-1 = 0.656, BLEU-4 = 0.177
- Show, Attend and Tell – Soft (Xu 2015) BLEU-1 = 0.67, BLEU-4 = 0.195
- Show, Attend and Tell – Hard (Xu 2015) BLEU-1 = 0.67, BLEU-4 = 0.213
- **NOSALTRES – ViT-GPT2 fine-tuned (2026)** **BLEU-1 = 0.724,** **BLEU-4 = 0.291**
- Ensemble + Attention (arXiv:2501.14828, 2025) BLEU-1 = 0.728,

Anàlisi qualitatiu (BLEU-1)

millor BLEU-1

BLEU-1=1.00 CLIP=28.6
Pred: a man and a woman looking at a boat in the water



BLEU-1=1.00 CLIP=33.3
Pred: a dog drinking water from a faucet



BLEU-1=1.00 CLIP=32.0
Pred: a brown and white dog standing in the sand



pitjor BLEU-1

BLEU-1=0.10 CLIP=29.4
Pred: people standing around a grassy area



BLEU-1=0.15 CLIP=29.3
Pred: people standing in the snow



BLEU-1=0.17 CLIP=24.7
Pred: a man and a woman sitting on a red and white trolley



Anàlisi qualitatiu (CLIPScore)

millor CLIPScore

BLEU-1=0.50 CLIP=38.8
Pred: a little girl laying in a pile of hay



BLEU-1=1.00 CLIP=36.4
Pred: a brown dog running through a grassy field



BLEU-1=0.78 CLIP=36.3
Pred: two dogs playing in the water with each other



pitjor CLIPScore

BLEU-1=0.57 CLIP=17.8
Pred: a woman standing next to a stone wall with a ball in her han



BLEU-1=0.42 CLIP=19.1
Pred: a woman sitting on a chair in front of a beach



BLEU-1=0.62 CLIP=19.6
Pred: a man riding a skateboard down a street



Diagnòstic de lèxic

Cada imatge rep una caption diferent, però el model usa només el 20 % del vocabulari

621

vocab predicció

vs 3 084 a les referències de test

20 %

del lèxic de les referències

ús del vocabulari disponible

99.8 %

captions úniques

no és un problema estructural, només lèxic

Plantilles repetides (top n-grams)

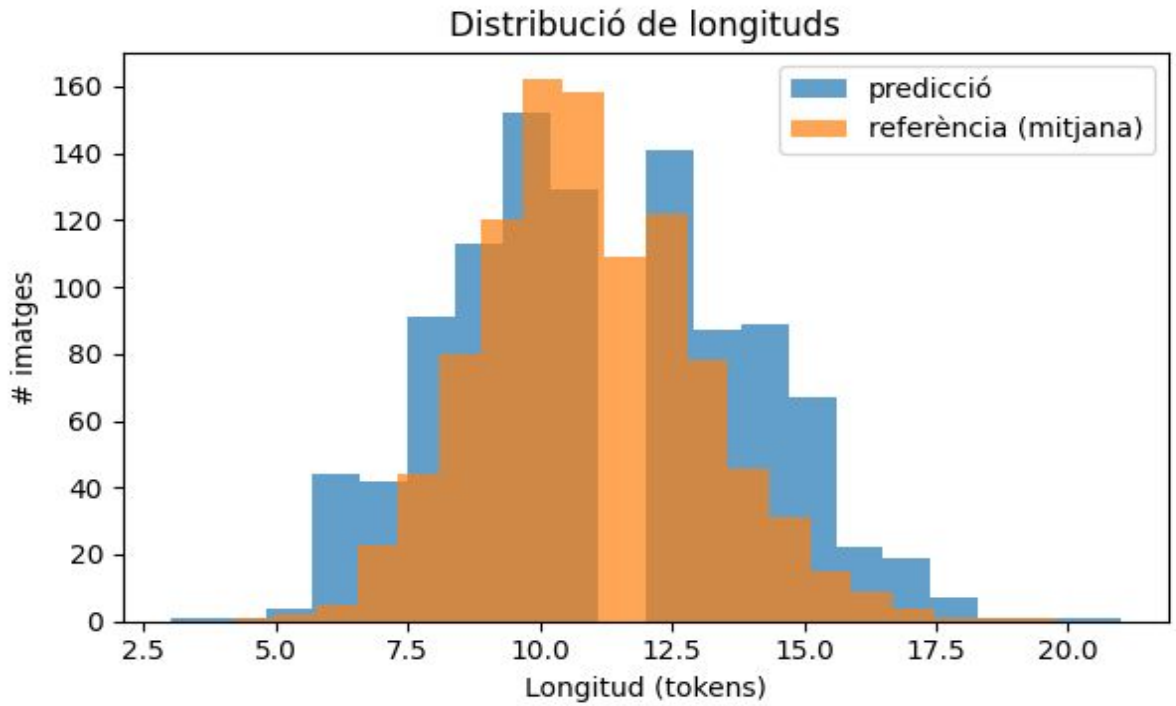
```
"a brown dog"
"a man in"
"dog is running"
"and white dog"
"a X in a red shirt"
```

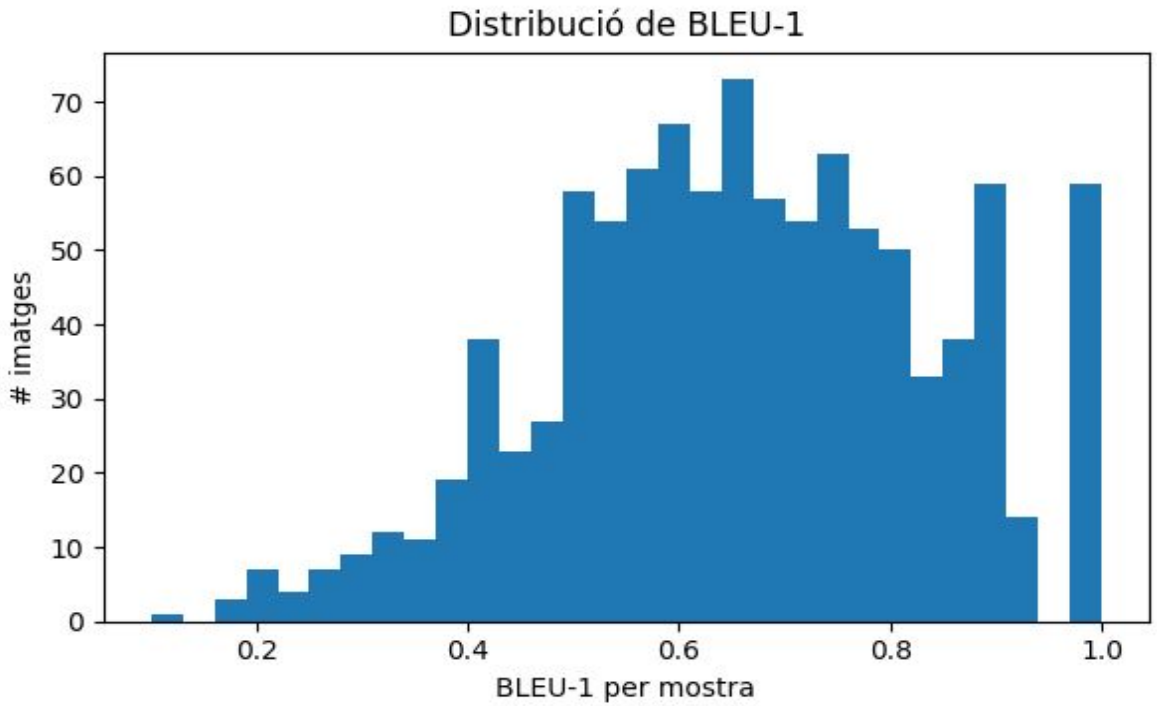
Què implica

- El model fa servir plantilles freqüents en lloc d'explorar el vocabulari
- Beam search amplifica el problema (sempre tria la més probable)
- Intenta encaixar una plantilla forçadament quan l'escena no s'ajusta al patró típic

Distribucions sobre el test

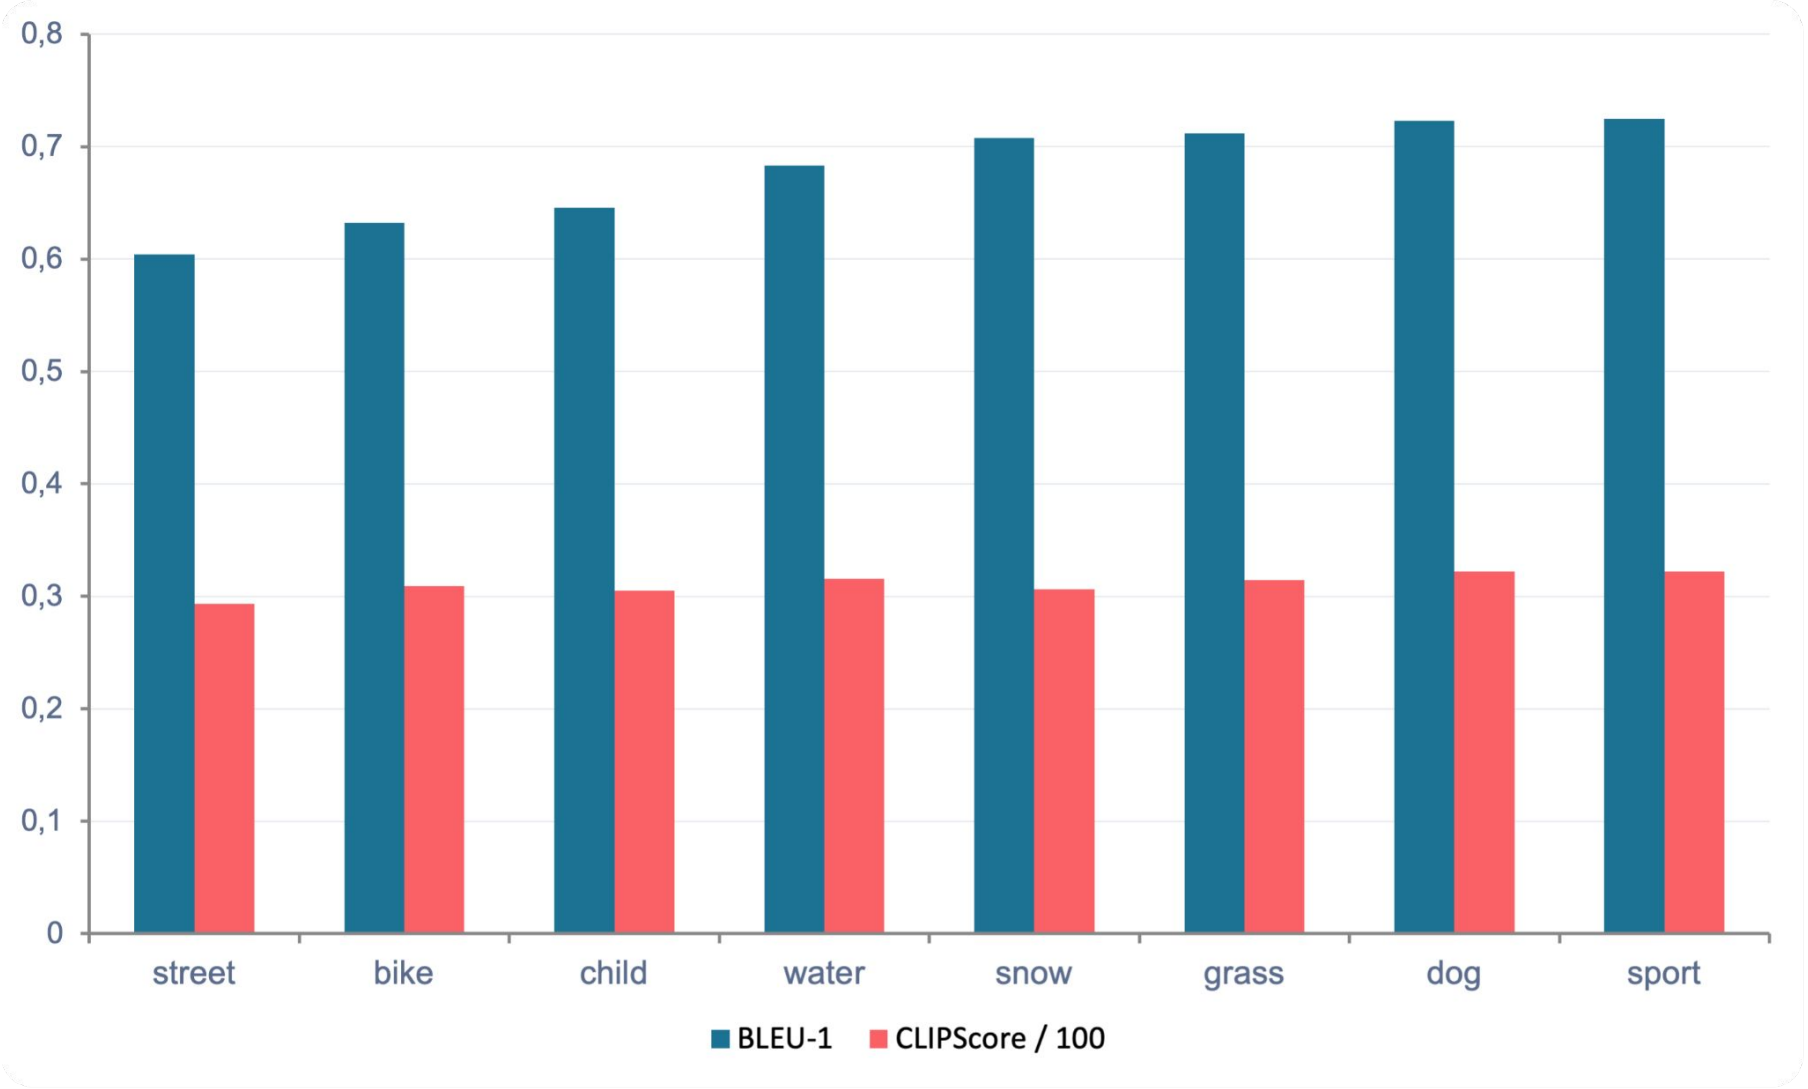
Longitud predicció vs referència - BLEU-1 per mostra (v3)





Rendiment per categoria visual

Detecció per keywords a les referències, quines escenes domina el model?



Diagnòstic de biaix de gènere

Imatges de dataset predites com a home, però amb referències mencionant una dona (keywords relacionades amb dona).

BLEU-1=0.36 CLIP=31.6
Pred: a boy jumps into the air above the water .



BLEU-1=0.55 CLIP=26.7
Pred: a man in a red jacket is throwing a yellow balloon .



BLEU-1=0.67 CLIP=26.8
Pred: a little boy is playing in a water fountain .



Diagnòstic de biaix de gènere

Asimetria 2.6×. Una dona té 2.6 cops més probabilitat de ser mal etiquetada que un home

ref \ pred	man	woman	neutral	both	% swap
man (1 646)	1135	**100**	282	129	**6.1 %**
woman (1 087)	**173**	706	102	106	**15.9 %**
neutral (1 592)	49	20	1474	49	**2.45×**
both (417)	67	88	88	174	-

Heatmaps d'atenció



Atenció sobre la regió correcta, però paraula 'boy' equivocada→
no és un error visual

Re-weight de tokens femenins a CE loss

40 token IDs (woman, girl, she, her, mother...)

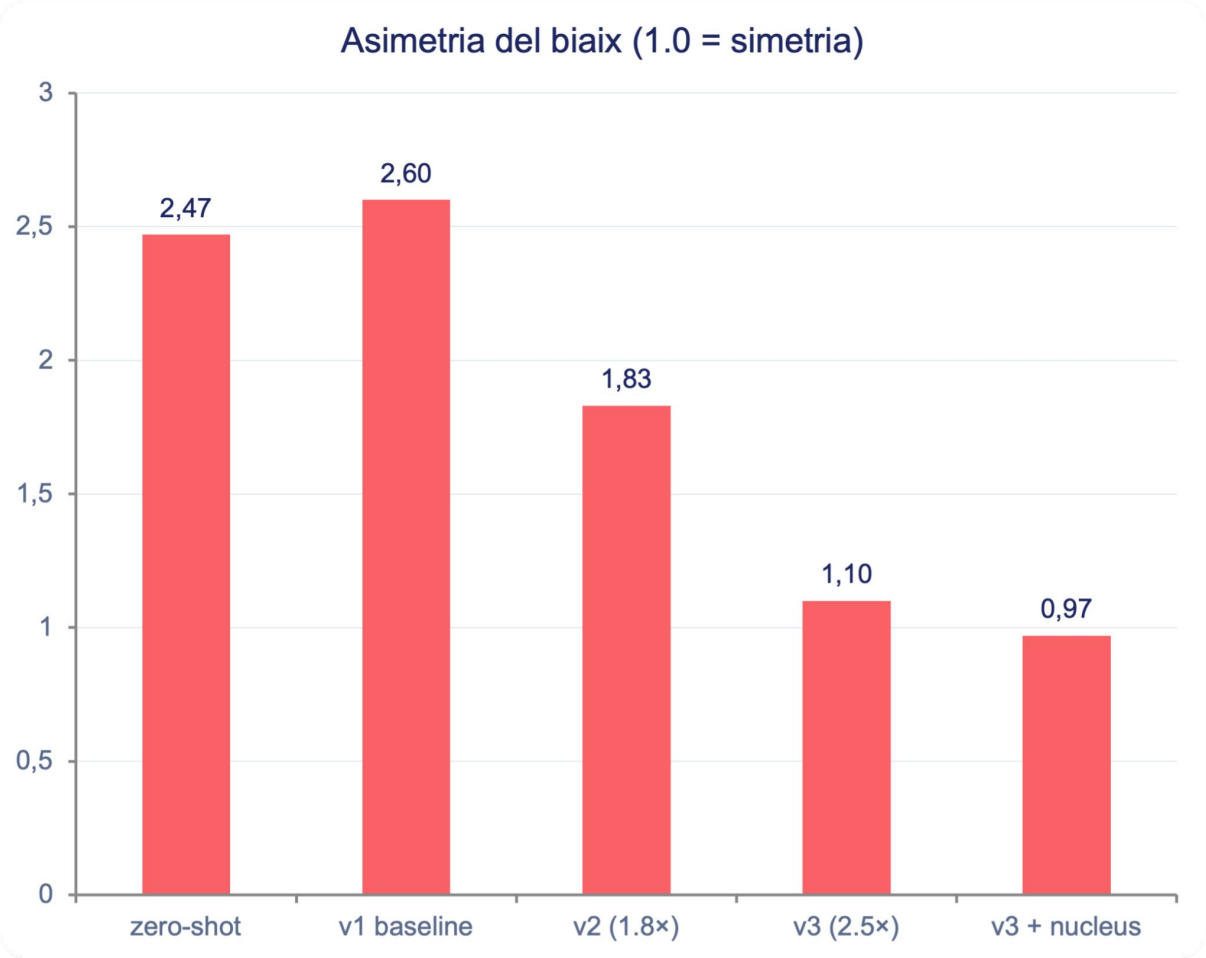
```
weights = torch.ones(vocab_size)
weights[female_token_ids] = w
CrossEntropyLoss(weight=weights)
```

Resultats

Variant	woman→man	man→woman	Asimetria	Neutrals →M	BLEU-1 / CLIP
v1 baseline	15.9 %	6.1 %	**2.60×**	2.45× M	0.724 / 30.18
v2 (w=1.8)	14.1 %	7.7 %	1.83×	1.83× M	0.721 (-0,003) / 30.13 (-0,05)
v3 (w=2.5)	**12.8 %**	**11.6 %**	**1.10×**	**1.29×**	0.716 (-0,008) / 30.07 (-0,11)

D'on ve el biaix?

Comparativa amb el ViT-GPT2 base (sense fine-tuning a Flickr8k)

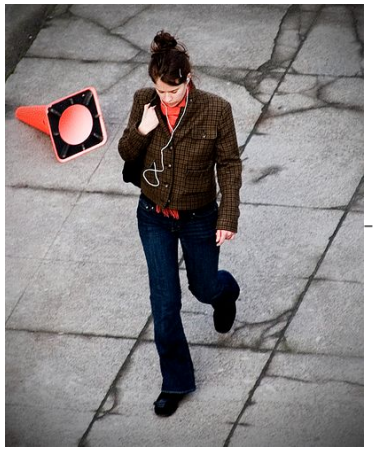


Variant	Ref. neutre → man	Ref. neutre → woman	Ratio M/W
zero-shot	14	1	14.0×
v1 baseline	49	20	2.45×
v3 (CE weight 2.5×)	9	7	1.29×

Comparativa qualitativa v1 vs v3



Referència	v1 baseline	v3 (CE weight 2.5×)
"a girl in a black two-piece is leaping into the water"	*"a boy jumps into the air above the water ."*	*"a girl in a black swimsuit jumps into the pool"*



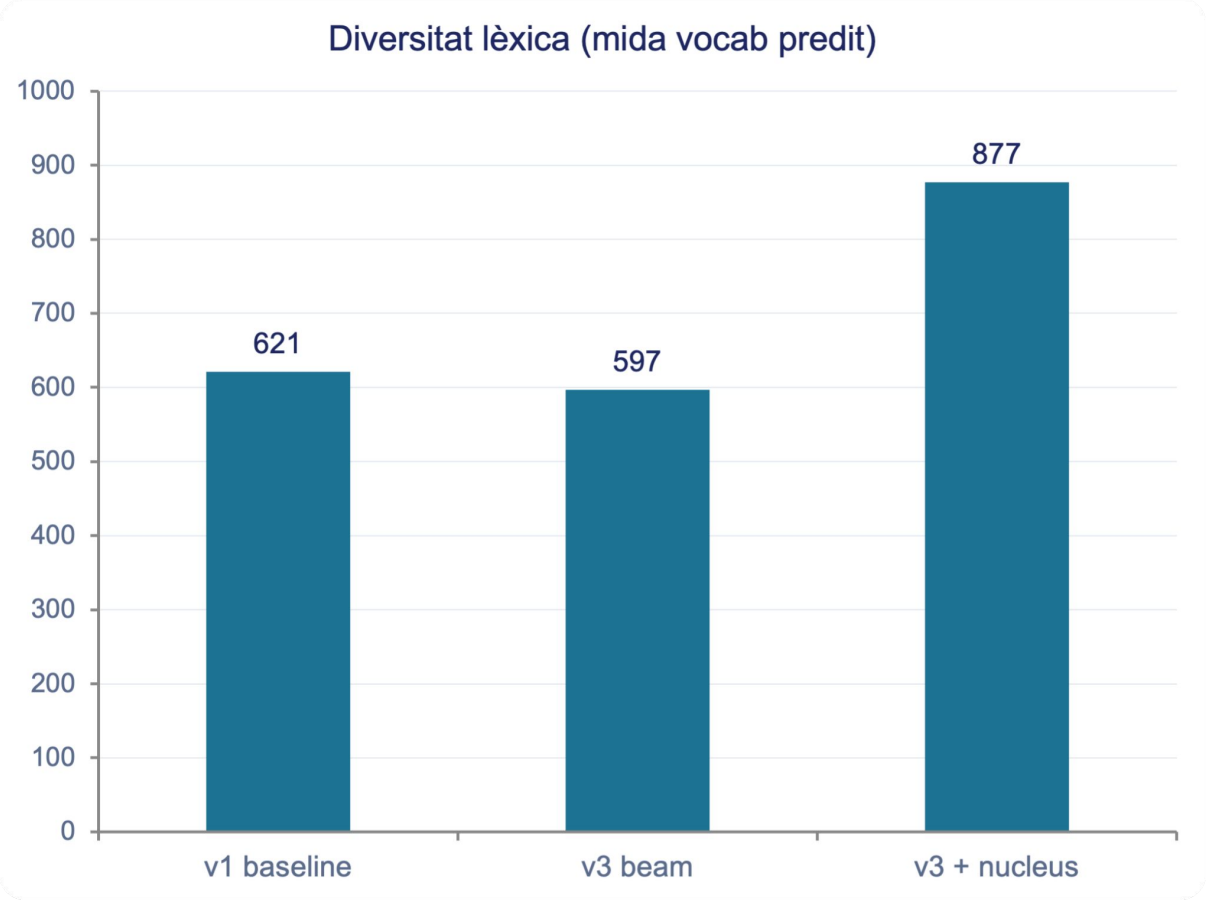
"a girl wearing a brown jacket and blue jeans has on some white headphones and is walking"	*"a man in a red jacket is throwing a yellow balloon"*	*"a woman in a red jacket is holding a yellow balloon"*



"a little girl in a metal tub filled with water"	*"a little boy is playing in a water fountain"*	*"two girls posing in front of a flag"*

Nucleus sampling

top_p=0.9, temperature=0.9 sobre el mateix checkpoint v3



v3 beam → v3 + nucleus

Mètrica	Δ
Vocab. predit	**+47 % (19,4% → 28,4%)**
Asimetria de gènere	**1.10 → 0.97×**
BLEU-1 mitjà	**−0.096**
CLIPScore mitjà	**−1.1**

Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2020). The curious case of neural text degeneration. arXiv preprint arXiv:1904.09751. [1]

Conclusions

Conclusió global

ViT-GPT2 + fine-tuning arriba a BLEU-1 ≈ 0.72 i CLIP ≈ 31 sobre Flickr8k

- Hem adaptat ViT-GPT2 a Flickr8k fent fine-tuning per capes.
- Hem analitzat biaixos i ús del vocabulari, i els hem reduït amb intervencions concretes que no degraden BLEU ni CLIP.
- Evolució del baseline ResNet+GRU al ViT-GPT2 fine-tuned, amb sweep d'hiperparàmetres.

Biaix de gènere

Asimetria 2.60× ⟶ 1.10× sense degradar BLEU ni CLIP (pràcticament)

- Biaix original al model base
- Reducció del biaix modificant pesos de CE sobre els tokens femenins
- Visualitació de cross-attention per confirmar que el problema és al decoder.
- Nucleus sampling permet augmentar el lèxic (vocab +47 %)

Next steps

Què faríem amb més temps?

- Test estadístic per comparar v1 vs v3.
- Sweep complet de female_token_weight per trobar el millor valor dels pesos.
- Anàlisi singular/plural per corregir aquest tipus d'errors també.
- Extensió a altres biaixos (edat, raça)
- Provar amb altres datasets